



КТ1. Анализ цен на квартиры от их площадей

Подготовил С.Кирилл

Оглавление

Оглавление

1. Загрузка данных

Код

Результат

Вывод

2. Предобработка данных

Код

Результат

Вывод

3. Построение модели линейной регрессии с использованием МНК

Формулы

Код

Результат

Вывод

4. Оценка качества модели

Формулы

Код

Результат

Вывод

5. Визуализация результатов

Код

Вывод

1. Загрузка данных

Код

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
df = pd.read_csv('train.csv') # Загружаю данные
SalePrice=df['SalePrice'] # Беру столбец с ценой
GrLivArea=df['GrLivArea'] # И с площадью квартиры
print(SalePrice.head)# Проверяю как отображаются данные
print(GrLivArea.head)
```

Результат

```
<bound method NDFrame.head of 0      208500
1      181500
2      223500
3      140000
4      250000
...
```

```
1455 175000
1456 210000
1457 266500
1458 142125
1459 147500
Name: SalePrice, Length: 1460, dtype: int64>
<bound method NDFrame.head of 0      1710
1      1262
2      1786
3      1717
4      2198
...
1455    1647
1456    2073
1457    2340
1458    1078
1459    1256
Name: GrLivArea, Length: 1460, dtype: int64>
```

Вывод

Данные корректно отображаются, я выбрал площадь квартиры (`GrLivArea`) и цену за квартиру (`SalePrice`).

Для наглядности напишу один раз следующие обозначения;

Предиктор здесь - `GrLivArea` (обозначу как S (площадь), а зависимая переменная - `Sale price` (пусть будет стоимость - P)

Регрессия будет следующей (забегаю вперед). Буду записывать на общий случай, то есть при $n = 1$ (далее будет другая запись, более привычная).

$$P = w_n + w_{n+1} \cdot S$$

2. Предобработка данных

Код

```
# Удаляю дубликаты только по площади и цене
df = df.drop_duplicates(subset=['GrLivArea', 'SalePrice'])

# Удаляем пропуски в этих столбцах
df = df.dropna(subset=['GrLivArea', 'SalePrice'])
```

Результат

Из данных убрались дубликаты и пустые значения

Вывод

Из данных убрались дубликаты и пустые значения. Ниже проверю что медиана нормально считается, уже столкнулся с тем что применение функций на всю таблицу выдавало ошибки при поиске медианы - `nan$` (поэтому указываю на нужные мне столбцы).

3. Построение модели линейной регрессии с использованием МНК

Формулы

$$J(w) = \sum_{i=1}^m (y_i - \hat{y}_i)^2 = \sum_{i=1}^m (y_i - w^T x_i)^2$$

$$\frac{\partial J(w)}{\partial w} = -2 \sum_{i=1}^m x_i (y_i - \hat{y}_i)$$

$$X^T(y - Xw) = 0$$

$$X^T X w = X^T y$$

$$w = (X^T X)^{-1} X^T y$$

Код

```
# Разделяю данные на признаки (X) и целевые значения (y)
X = GrLivArea.values # Площадь квартиры
y = SalePrice.values # Цена

# Добавляю колонку единиц для учета свободного члена (w0)
X_ = np.c_[np.ones(X.shape[0]), X]

# Транспонирую матрицу X
X_T = X_.T

# Вычисляю X^T * X
X_T_X = X_T.dot(X_)

# Вычисляю X^T * y
X_T_y = X_T.dot(y)

# Решаю нормальные уравнения для коэффициентов
w = np.linalg.inv(X_T_X).dot(X_T_y)

# Коэффициенты
w0, w1 = w[0], w[1]

# Вывожу коэффициенты
print(f"Коэффициенты: w_n = {w0:.2f}, w_{n+1} = {w1:.2f}")
```

Результат

```
Коэффициенты: w_n = 18569.03, w_{n+1} = 107.13
```

Вывод

$$\hat{y} = w_n + w_{n+1} \cdot X$$

$$P = 18569 + 107.13 \cdot S$$

Таким образом, базовая стоимость идет от 18569 \$.
Цена за единицу площади увеличивается на 107.13 \$.

Например при $S = 100$ квадратах цена будет $P = 18569 + 107.13 \cdot 100 = 29,282 \$$

4. Оценка качества модели

Формулы

$$\text{MSE} = \frac{1}{m} \sum_{i=1}^m (y_i - \hat{y}_i)^2$$

$$R^2 = 1 - \frac{\sum (y_i - \hat{y}_i)^2}{\sum (y_i - \bar{y})^2}$$

Код

```
y_pred = X_.dot(w) # Использую X_, т.к. там добавлен столбец единиц для свободного члена

# Вычисляю MSE (Среднеквадратичная ошибка)
mse = np.mean((y - y_pred)**2)
print(f"Среднеквадратичная ошибка (MSE): {mse:.2f}")

# Вычисляю R^2 (Коэффициент детерминации)
sst = np.sum((y - np.mean(y))**2) # Суммарная вариация
sse = np.sum((y - y_pred)**2) # Сумма квадратов ошибок
r2 = 1 - sse / sst

print(f"Коэффициент детерминации (R^2): {r2:.2f},")

median = np.median(df['SalePrice'])
print(f"Медианная цена: {median:.0f}$")
```

Результат

Среднеквадратичная ошибка (MSE): 3139843209.67
Коэффициент детерминации (R^2): 0.50,
Медианная цена: 163500\$

Вывод

$$\sqrt{MSE} = 56$$

$\sqrt{MSE} = 56034$ означает что типичная ошибка предсказания $\pm 56,035 \$$. Это достаточно большая ошибка, если учитывать что медиана равна 163500 \$.

То есть ошибка занимает **треть** медианы, что определенно говорит о статистически значимой среднеквадратичной ошибке.

Модель пригодна для грубых оценок и подходит для оценки общих трендов (не для индивидуальных предсказаний). Также очевиден разброс значений, это также объясняется только 50% объясняемостью данных по одному значению, то есть количество информации весьма ограничено для точных прогнозов.

$R^2 = 0.5$ означает что модель объясняет 50% дисперсии цен.

Только 50% данных объясняется площадью квартиры. Думаю это хорошая переменная для поиска зависимости. Возможно остальные 50% данных зависят от комбинации из других переменных. Но я смотрю влияние одного признака.

5. Визуализация результатов

Код

```
plt.figure(figsize=(10, 6)) # Создаю полотно, указываю его размер

plt.scatter(X, y, color='blue', label='Исходные данные') # график точек

plt.plot(X, y_pred, color='red', label='Линия регрессии') # линия регрессии


plt.xlabel('Площадь (кв. м)')

plt.ylabel('Цена (тыс. долларов)')
```

```
plt.title('Линейная регрессия: Площадь vs Цена')
```

```
plt.legend()
```

```
plt.show()
```



Вывод

На графике хорошо видно, что выбросы существуют, на это указывают точки на скаттере (примерно после 3000 кв.м или 400 000 долларов).

По наклону оси видно что тенденция роста цены от площади существует. В некоторый моменит начинают преобладать выбросы, что объясняется нелинейностью интерпритации (на элитную недвижимость цена может сильно разниться, возможно существенную роль ценообразования начинают играть другие параметры). Поэтому для больших площадей нужна нелинейная интерпритация.