



КТ2. Непараметрические подходы

Подготовил С.Кирилл

Оглавление

Оглавление

- 1. Выбор данных и предварительный анализ
 - Код
 - Результат
 - Код
 - Результат
 - Вывод
- 2. Расчёт классических и робастных статистик
 - Код
 - Результат
- 3. Масштабированный бутстрэп-анализ
 - Код
 - Результат
- 4. Визуализация результатов
 - Код
 - Результат
 - Вывод
- 5. Аналитический отчёт

1. Выбор данных и предварительный анализ

Числовая переменная из датасета, которую я выбираю - `SessionLengthMin`.

Провожу быстрый обзор.

Код

```
import pandas as pd # Указываю библиотеки и свои обращения к ним
import numpy as np
import matplotlib.pyplot as plt
```

```
df = pd.read_csv('ai_assistant_usage_student_life.csv') # Загружаю данные из файла
print("Основные статистики SessionLengthMin:")
print(df['SessionLengthMin'].describe()) # Использую простую команду на общее описание
```

Результат

```
Основные статистики SessionLengthMin:
count    10000.000000
mean      19.846467
std       13.897302
min        0.030000
25%        9.630000
50%       16.650000
75%       26.670000
max       110.810000
Name: SessionLengthMin, dtype: float64
```

Код

Общий диапазон:

```
import pandas as pd
import numpy as np
Q1 = df['SessionLengthMin'].quantile(0.25) # 25-й процентиль
Q2 = df['SessionLengthMin'].quantile(0.5) # 50-й процентиль
Q3 = df['SessionLengthMin'].quantile(0.75) # 75-й процентиль
IQR = Q3 - Q1
lower_bound = Q1 - 1.5 * IQR
upper_bound = Q3 + 1.5 * IQR
min_value = df['SessionLengthMin'].min()
max_value = df['SessionLengthMin'].max()
print (f'''25-й процентиль : {Q1} мин. 75-й процентиль : {Q3} мин., межквартильный размах : {IQR} мин.
Медиана : {Q2}мин
\nНижняя граница : {lower_bound} мин. , верхняя : {upper_bound} мин.
\n Минимальное значение : {min_value} мин. )
\n Максимальное значение : {max_value} мин. )
\n Размах : {max_value-min_value} мин. ''')
```

Результат

```
25-й процентиль : 9.63 мин. 75-й процентиль : 26.67 мин., межквартильный размах : 17.04 мин.
Медиана : 16.65мин

Нижняя граница : 15.929999999999998 мин. , верхняя : 52.230000000000004 мин.

Размах : 110.78 мин.
```

Вывод



50% всех сессий длятся от 9.63 до 26.67 минут

Медиана - 16.65 минуты

Межквартильный размах $26.67 - 9.63 = 17.04$ минуты является достаточно существенным, учитывая, что это $\frac{17.04}{16.65} = 1.02$, то-есть превышает саму медиану чуть больше чем на 1% (использую это отношение для сравнения и наглядности).

$$\frac{IQR}{MED} = \frac{17.04}{16.65} = 1.02$$

Как итог - выбросы существуют, и они статистически значимы. Диапазон всего - 10 000 значений, их размах - 110.78 мин.

D

$$LB = Q1 - 1.5 \cdot IQR$$

$$UB = Q3 + 1.5 \cdot IQR$$

2. Расчёт классических и робастных статистик

Рассчитываю следующие значения;

Среднее, стандартное отклонение, медиану, усечённое среднее, медианное абсолютное отклонение, оценку Ходжеса–Лемана.

Код

```
import pandas as pd
from scipy.stats import trim_mean

# Загрузка данных
df = pd.read_csv('ai_assistant_usage_student_life.csv')

# Расчёт статистик
mean = df['SessionLengthMin'].mean() # нахожу среднее
std = df['SessionLengthMin'].std()   # стандартное отклонение
med = df['SessionLengthMin'].median() # медиану
trim_mean_value = trim_mean(df['SessionLengthMin'], proportiontocut=0.1) # усечённое среднее с 10% отсечёнными значениями

# Медианное абсолютное отклонение (MAD)
mad = (df['SessionLengthMin'] - med).abs().median() # медианное абсолютное отклонение

# Оценка Ходжеса–Лемана
hodges_lehmann = (df['SessionLengthMin'].min() + med) / 2 # Оценка Ходжеса–Лемана

# Для вывода использую F-строку
print(f'Среднее = {mean}, \nСтандартное отклонение = {std}, \nМедиана = {med}, '
      f'Усечённое среднее = {trim_mean_value}, \nМедианное абсолютное отклонение = {mad}, '
      f'Оценка Ходжеса–Лемана = {hodges_lehmann}')
```

Результат

Среднее = 19.846466999999997,
 Стандартное отклонение = 13.89730198808984,
 Медиана = 16.65, Усечённое среднее = 18.096404999999997,
 Медианное абсолютное отклонение = 8.069999999999999, Оценка Ходжеса–Лемана = 8.34

3. Масштабированный бутстрэп-анализ

Провожу бутстреп с различным числом выборок и рассчитываю из выбранных статистик 95% доверительный интервал и стандартную ошибку.

Код

```
import numpy as np
import matplotlib.pyplot as plt

# Данные времени отклика сервера (в секундах)
data = df['SessionLengthMin'].values

# Функция бутстрэппинга для медианы
def bootstrap_median(data, B):
    n = len(data)
    medians = np.empty(B)
    for i in range(B):
        sample = np.random.choice(data, size=n, replace=True)
        medians[i] = np.median(sample)
    return medians

# Значения B для эксперимента
B_values = [100, 1000, 10000]

# Настроим цвета для графиков
colors = ["#b41f44", "#ffef0e", "#2c4ba0"]

plt.figure(figsize=(15, 10))

# Цикл по B_values для расчета медиан и построения графиков
for i, B in enumerate(B_values):
    # Получаем медианы с бутстрэпом
    medians = bootstrap_median(data, B)

    # Рассчитываем доверительные интервалы
    lower = np.percentile(medians, 2.5)
    upper = np.percentile(medians, 97.5)
    median_original = np.median(data)
    interval_width = upper - lower

    # Стандартная ошибка медианы (стандартное отклонение медиан)
    se_median = np.std(medians, ddof=1)

    # Выводим результаты
    print(f"B = {B}")
    print(f" Исходная медиана: {median_original:.3f}")
    print(f" 95% доверительный интервал медианы: [{lower:.3f}, {upper:.3f}]")
    print(f" Ширина интервала: {interval_width:.3f}")
    print(f" Стандартная ошибка медианы: {se_median:.3f}\n")

    # Построение гистограммы распределения бутстрэпных медиан
    plt.subplot(3, 1, i+1)
    plt.hist(medians, bins=30, color=colors[i], alpha=0.7, edgecolor='black')
    plt.axvline(median_original, color='black', linestyle='--', label='Исходная медиана')
    plt.axvline(lower, color='red', linestyle='-', label='2.5-й перцентиль')
    plt.axvline(upper, color='red', linestyle='-', label='97.5-й перцентиль')
    plt.title(f'Распределение медиан (B={B})')
```

```
plt.xlabel('Медиана времени отклика (сек)')
plt.ylabel('Частота')
plt.legend()
```

```
plt.tight_layout()
plt.show()
```

Результат

```
B = 100
Исходная медиана: 16.650
95% доверительный интервал медианы: [16.369, 16.870]
Ширина интервала: 0.500
Стандартная ошибка медианы: 0.136


B = 1000
Исходная медиана: 16.650
95% доверительный интервал медианы: [16.380, 16.965]
Ширина интервала: 0.585
Стандартная ошибка медианы: 0.150

B = 10000
Исходная медиана: 16.650
95% доверительный интервал медианы: [16.380, 16.940]
Ширина интервала: 0.560
Стандартная ошибка медианы: 0.147
```

4. Визуализация результатов

Тот же код выше визуализирует следующие 3 графика.

Строю гистограммы распределения бустрэп-значений для всех статистик




Код

```
import numpy as np
import matplotlib.pyplot as plt
B_values = [100, 1000, 10000] # Выборки
ci_widths = [0.500, 0.585, 0.560] # Ширина ДИ
standard_errors = [0.136, 0.150, 0.147] # Стандартные ошибки из нового вывода

plt.figure(figsize=(8, 4))
plt.plot(B_values, ci_widths, 'o-', label='Ширина 95% ДИ', linewidth=2, markersize=8)
plt.plot(B_values, standard_errors, 's-', label='Стандартная ошибка', linewidth=2, markersize=8)
plt.xlabel('Количество бутстрэп-выборок')
plt.ylabel('Значение')
plt.title('Зависимость от количества бутстрэп-выборок')
plt.legend()
plt.grid(True, alpha=0.3)
plt.xscale('log')
plt.show()
```

Результат



Вывод



Ширина доверительного интервала (ДИ) для медианы немного выше, чем **стандартная ошибка** медианы при одинаковом количестве бутстрэп-выборок.

Изменения ширины доверительного интервала (ДИ) и стандартной ошибки (SE) составляют не более 0.1 при изменении числа выборок B .

Это может свидетельствовать о **малых отклонениях**, что, в свою очередь, указывает на **высокую стабильность** оценок.

Сравнивая классические оценки с робастными я могу сделать несколько выводов;

Пусть рассматривается значение n

Медиана $\tilde{n} = 16.65$ как робастная оценка показывает значение, которое менее подвержено влиянию выбросов, поскольку значения $n_m, n_{m+1}, \dots, n_{i-1}, i$ раскладываются в порядке возрастания и медианой считается середина списка. В отличие от среднего $\bar{n} = 19.85$ (округлю до 2 знаков в большую сторону) она показывает значение ниже на $\bar{n} - \tilde{n} = 3.2$, что дает более точный результат, поскольку среднее $\bar{n} = \frac{\sum_i n_i}{i}$ учитывает в счете самые низкие и высокие значения, которые попадают под определение выбросов.

Также надежность медианы подтверждает узкий ДИ.

Отдельно можно сказать про то, что стандартная ошибка в значениях не превышает 0.15 при всех выборках.

Все это показывает, что бустрэп является хорошим инструментом, который можно применять для данного исследования.

5. Аналитический отчёт

Полученные показатели для выборок B_n, B_{n+1}, B_{n+2} не сильно отличаются друг от друга (ширины ДИ - 0.500, 0.585, 0.560, стандартные ошибки - 0.136, 0.150, 0.147, соответствуют выборкам по порядку) и это может свидетельствовать о стабильности показателей.

Графики, отображающие распределения бутстрэпных медиан для различных значений B , показывают, как с увеличением числа выборок улучшает точность оценки медианы. Это наглядно иллюстрирует важность использования более крупных выборок для получения более стабильных и точных результатов.

Выбросы существуют и они статистически значимы. Результаты выше подтверждают мое высказывание.

Робастные методы, такие как медианное абсолютное отклонение (MAD), усечённое среднее, оценка Ходжеса-Лемана, помогают уменьшить влияние выбросов. Эти методы дают более устойчивые оценки и позволяют корректно оценить центральную тенденцию и разброс данных без искажения, вызванного экстремальными значениями.


Размах Δt в минутах равен 110.78 мин. (обозначаю для наглядности через LATEX формулы).

$$\Delta t = t_{max} - t_{min} = 110.81 - 0.03 = 110.78$$


Такая разница в длительности взаимодействия с пользователем может свидетельствовать о широкой вариабельности задач.

Например один пользователь задал один вопрос и сразу получил ответ, а другой мог общаться час в поисках ответа.

Но скорее всего, учитывая медианное значение в $\tilde{t} = 16.65$, оно может означать что некоторые пользователи могли по ошибке зайти (0.03 минуты), а некоторые забыли выйти из браузера к примеру, оставив открытым диалог с ней, при этом не пользуясь самой системой.



Распределение медиан при различных выборках



Зависимости от количества бустреп-выборок

$B_n = 100$
 $B_{n+1} = 1000$
 $B_{n+2} = 10000$
 при $n = 1$